

INFORME DEL PROYECTO: MODULE-10-FINAL-DATA-PROJECT

Autor: Miguel Encinas Gimenez

1. INTRODUCCIÓN

Este proyecto corresponde al proyecto final del Módulo 10 del programa Data & Analytics V3 de thePower. El objetivo principal ha sido aplicar un flujo completo de análisis de datos sobre un conjunto de datos real relacionado con partidos históricos de la NBA.

El proyecto se ha centrado en integrar dos fuentes de datos diferentes: una tabla principal con estadísticas de equipo por partido, *TeamStatistics.csv*, y una segunda tabla con información histórica basada en el sistema Elo, *nbaallelo.csv*. La primera tabla aporta información detallada sobre *box score*: resultado, marcador, condición local/visitante y tipo de partido. La segunda tabla aporta métricas relacionadas con Elo: *forecast* y fuerza relativa de los equipos antes y después de cada partido.

Tras limpiar, transformar y unir ambas fuentes, se generó un conjunto de datos final llamado *03_Merge_TeamStats_TeamElo.csv*. Este conjunto de datos tiene una estructura a nivel equipo-partido, lo que significa que cada partido real aparece normalmente dos veces: una fila desde el punto de vista de cada equipo. Esta estructura permite analizar tanto el rendimiento de cada equipo como la relación entre estadísticas de juego, resultados y predicciones Elo.

2. OBJETIVOS DEL PROYECTO

Los objetivos principales del proyecto han sido los siguientes:

1. Realizar una limpieza profunda de los datos originales.
2. Homogeneizar columnas, formatos, nombres de equipos y categorías.
3. Crear variables estadísticas útiles para el análisis.
4. Combinar dos conjuntos de datos diferentes mediante una clave común (*GameID*) construida durante el proceso.
5. Realizar un análisis descriptivo del conjunto de datos final.
6. Realizar un análisis estadístico sobre rendimiento, ventaja local, *box score* y Elo.
7. Construir un dashboard operativo en Power BI.

3. FUENTES DE DATOS

3.1. TeamStatistics.csv

TeamStatistics.csv es la tabla principal del proyecto. Contiene estadísticas a nivel de equipo en cada partido. Entre sus variables originales se encontraban: fecha del partido, equipo, rival, condición local/visitante, resultado, puntuación, asistencias, tapones, robos, etc. Esta tabla era la más completa desde el punto de vista del *box score*, pero también presentaba numerosos valores nulos, columnas poco útiles para el análisis final y algunas variables que requerían transformación. Fue obtenida de la siguiente fuente: <https://www.kaggle.com/datasets/eoinamoore/historical-nba-data-and-player-box-scores>

3.2. nbaallelo.csv

Tabla histórica con información Elo para partidos NBA. El Elo es un sistema de puntuación que intenta medir la fuerza relativa de un equipo. En este proyecto se han usado principalmente variables como *Elo_Before*, *Elo_After*, *Elo_Before_Rival*, *Elo_After_Rival* y *Forecast*. La ventaja de esta tabla es que permite analizar no sólo lo que ocurrió en cada partido, sino también qué resultado

era esperable antes de jugarlo según la fuerza relativa de los equipos. Dicho conjunto de datos fue obtenido del siguiente enlace: <https://datahub.io/fivethirtyeight/nba-elo>

4. LIMPIEZA Y TRANSFORMACIÓN DE LOS DATOS

El proceso de limpieza de estos datos se dividió en tres scripts principales.

4.1. Limpieza de TeamStatistics.csv

En el archivo **01_EDA_TeamStatistics.csv.py** se realizó la exploración y limpieza de esta tabla, catalogada como principal.

Primero se cargó el conjunto de datos con pandas y se revisaron las dimensiones, tipos de datos y valores nulos. La fecha del partido se convirtió a formato *datetime* para poder extraer variables temporales como *Game_Day*, *Game_Month* y *Game_Year*.

Durante la revisión de valores nulos se tomaron ciertas decisiones en función de la naturaleza de cada variable. Se eliminaron, por ejemplo, registros asociados a partidos *All-Star*, o partidos fuera de la liga o con datos incompletos en estadísticas esenciales. También se detectó un caso concreto en *threePointersPercentage* donde el valor nulo significaba una división 0/0 al no haberse intentado ningún triple. En ese caso, el valor se sustituyó por 0.

Se revisó por otra parte la columna *numMinutes* (minutos totales de partido). Al tratarse de estadísticas de equipo, los valores esperables eran 240 minutos para partidos sin prórroga y valores como 265, 290, 315 o superiores para partidos con prórrogas. Se eliminaron filas con valores no coherentes o nulos. Además, algunas columnas como *q1Points*, *q2Points*, *q3Points*, *q4Points*, *benchPoints*, *biggestLead*, *pointsFastBreak*, *timesTied*, *seasonWins* o *seasonLosses* presentaban muchos valores nulos o no eran esenciales para los objetivos del análisis. Por ello, se eliminaron para conservar el mayor número posible de partidos útiles sin comprometer la calidad del conjunto de datos final.

Por otra parte, también se eliminaron columnas consideradas redundantes o poco informativas, como *coachId*, *gameLabel*, *gameSubLabel*, *seriesGameNumber*, *seed*, *reboundsTeam*, o *turnoversTeam*. Posteriormente, se filtraron los datos para conservar partidos desde 1985 en adelante y únicamente partidos de Regular Season y Playoffs. Se transformaron variables binarias en categorías más legibles, como en el caso de *Home/Away* o *Win/Loss*.

Por último, se creó la variable *Season* para representar la temporada NBA en formato año/año, considerando que las temporadas se desarrollan entre octubre y junio. Finalmente, se generó un identificador propio llamado *Game_ID*, combinando la fecha del partido y las tres primeras letras del equipo, para facilitar la unión posterior con la tabla Elo.

4.2. Limpieza de nbaallelo.csv

En el archivo **02_EDA_TeamElo.py** se realizó asimismo la limpieza de la tabla Elo.

Durante la carga del archivo se detectó un problema de lectura: algunas filas presentaban más campos de los esperados. Para solucionarlo, se cargó el archivo excluyendo las columnas adicionales que no aportaban información útil. Tras esto, se eliminaron columnas poco relevantes o redundantes para el análisis final, como *notes*, *lg_id*, *iscopy*, *year_id*, *date_game*, *is_playoffs*, *pts*, *opp_id*, *game_result* o *win_equiv*. Se conservaron, por su parte, las variables relacionadas con el sistema Elo y se crearon nuevas columnas analíticas:

- **Elo_Variation:** variación del Elo del equipo después del partido.
- **Elo_Diff_PreGame:** diferencia entre el Elo del equipo y el Elo del rival antes del partido.

- **Favorite_by_Elo:** clasificación del equipo como *Favorite* o *Underdog* según la diferencia de Elo.
- **Favorite_by_Forecast:** clasificación basada en la probabilidad estimada de victoria.
- **Favorite_Category:** clasificación del grado de favoritismo en *Strong favorite*, *Favorite*, *Even matchup*, *Underdog* o *Strong underdog*.

4.3. Unión de TeamStatistics y TeamElo

En el archivo **03_Merge_TeamStats_TeamElo.py** se combinaron ambas tablas ya limpias y organizadas. El punto más delicado de esta fase fue la homogeneización de nombres de equipos y franquicias para poder crear posteriormente la variable *GameID*. La NBA tiene una larga historia de equipos que cambiaron de ciudad o nombre, y ambas fuentes no siempre utilizaban la misma nomenclatura. Para evitar errores en la unión de tablas, se revisaron y ajustaron diferentes casos históricos, entre ellos:

- Seattle SuperSonics y Oklahoma City Thunder.
- Washington Bullets y Washington Wizards.
- Charlotte Bobcats y Charlotte Hornets.
- Rochester/Cincinnati Royals y Sacramento Kings.
- Buffalo Braves y Los Angeles Clippers.
- Syracuse Nationals y Philadelphia 76ers.

Una vez equiparados los nombres, se reconstruyó el *Game_ID* en la tabla Elo siguiendo la misma lógica que en la tabla principal, y se realizó un *merge()* interno sobre *Game_ID*. Una vez realizada la unión, se eliminaron columnas redundantes y se crearon nuevas variables:

- **Score_Diff:** diferencia entre *Team_Score* y *Opponent_Score*.
- **Score_Diff_Classi:** clasificación del margen de puntos como *Close win*, *Comfortable win*, *Blowout win*, *Close loss*, *Comfortable loss* o *Blowout loss*.
- **Result/Expect:** diferencia entre el resultado real y el forecast esperado.
- **Result/Expect_Classi:** clasificación del resultado como *Expected win/loss*, *Unexpected win/loss* o *Surprising win/loss*.

5. DESCRIPCIÓN DEL CONJUNTO DE DATOS FINAL

El conjunto de datos final, **03_Merge_TeamStats_TeamElo.csv**, contiene **71.984 registros y 47 columnas**. Su unidad de análisis es el equipo-partido, no el partido único; por tanto, cada partido aparece generalmente dos veces: una desde la perspectiva del equipo local o visitante y otra desde la perspectiva de su rival.

El conjunto de datos incluye **31 temporadas**, desde 1984/1985 hasta 2014/2015, y **36 nombres de equipos o franquicias**. La diferencia entre el rango inicial de *TeamStatistics.csv* y el rango final del conjunto de datos combinado se debe a que la tabla Elo utilizada cubre hasta 2015, por lo que el *merge()* final conserva únicamente los partidos presentes en ambas fuentes.

Algunas de las variables más relevantes del conjunto de datos final son:

- | | | |
|-------------|-----------------|---------------------|
| - Date_Time | - Opponent_Name | - Opponent_Score |
| - Season | - Home/Away | - Score_Diff |
| - Game_Type | - Win/Loss | - Score_Diff_Classi |
| - Team_Name | - Team_Score | - Assists |

- FG_Attempted	- Rebounds_DEF	- Elo_Diff_PreGame
- FG_Made	- Rebounds_OFF	- Favorite_by_Elo
- FG_%	- Rebounds_TOT	- Elo_After
- 3PT_Attempted	- Personal_Fouls	- Elo_Variation
- 3PT_Made	- Turnovers	- Forecast
- 3PT_%	- Steals	- Favorite_by_Forecast
- FT_Attempted	- Blocks	- Favorite_Category
- FT_Made	- Elo_Before	- Result/Expect
- FT_%	- Elo_Before_Rival	- Result/Expect_Classi

6. ANÁLISIS DESCRIPTIVO

El análisis descriptivo tuvo como objetivo comprender la estructura general del conjunto de datos y sus principales métricas agregadas.

El conjunto de datos final contiene aproximadamente **35.992 partidos reales** (considerando que cada partido aparece dos veces). La media de puntos anotados por equipo fue de **100,52 puntos**, el porcentaje medio de tiros de campo fue de **46,07%**, y el porcentaje medio de triples fue de **32,94%**.

En cuanto a estadísticas de *box score*, los equipos presentaron de media **42,44 rebotes totales**, **22,66 asistencias** y **14,83 pérdidas** por equipo-partido. La media de triples intentados fue de **13,71**, aunque este valor tiene una evolución muy relevante en el análisis de esta liga: en la temporada **1984/1985** la media de triples intentados era de aproximadamente **0,69**, mientras que en **2014/2015** alcanzó aproximadamente **22,60** intentos por equipo-partido. Esto confirma la evolución en el ritmo y estilo de juego que los seguidores de la NBA hemos ido notando con el paso de los años.

También se analizó la distribución por tipo de partido. La mayoría de los registros corresponden a *Regular Season*, mientras que los partidos de *Playoffs* representan una proporción mucho menor del conjunto de datos. Esto es esperable, ya que la temporada regular incluye muchos más partidos que las eliminatorias.

7. ANÁLISIS ESTADÍSTICO

7.1. Ventaja local

Uno de los resultados más claros del análisis fue la ventaja local. Los equipos locales ganaron aproximadamente el **61,79%** de sus partidos, mientras que los equipos visitantes ganaron aproximadamente el 38,43%.

Además, los equipos locales anotaron de media **102,37** puntos y recibieron **98,63**, con un margen medio positivo de 3,74 puntos. Por el contrario, los equipos visitantes anotaron de media 98,66 puntos y recibieron 102,31, con un margen medio negativo de -3,65 puntos. Esto confirma que jugar en casa está asociado históricamente a una ventaja clara en el rendimiento de los equipos.

7.2. Comparación entre victorias y derrotas

La comparación entre equipos ganadores y perdedores mostró diferencias claras en las estadísticas de juego. Por un lado, los equipos ganadores anotaron de media **106,00** puntos,

mientras que los perdedores anotaron **95,01**. También presentaron **más asistencias**, con 24,45 frente a 20,85; **más rebotes** totales, con 44,14 frente a 40,74; y **más robos**, con 8,28 frente a 7,38.

Por otro lado, los equipos ganadores cometieron **menos pérdidas**, con 14,33 frente a 15,33, y **menos faltas personales**, con 21,53 frente a 23,06. Estos resultados indican que ganar está asociado no sólo a anotar más, sino también a una mejor circulación de balón, mayor control del juego, y menor número de errores.

7.3. Elo y forecast

El análisis de Elo mostró que el sistema tiene una señal predictiva clara, ya que los equipos clasificados como *Favorite* ganaron aproximadamente el **65,54%** de los partidos. En cambio, los equipos clasificados como *Underdog* ganaron aproximadamente el **34,53%**.

La clasificación *Favorite_Category*, por su parte, mostró una distribución bastante coherente:

- **Strong favorite:** 82,45% de victorias.
- **Favorite:** 66,63% de victorias.
- **Even matchup:** 49,98% de victorias.
- **Underdog:** 33,52% de victorias.
- **Strong underdog:** 17,37% de victorias.

Esto indica que, cuanto mayor es el favoritismo previo, mayor es la probabilidad real de victoria.

Por otra parte, también se analizó la relación entre *Elo_Diff_PreGame* y *Score_Diff*. La correlación fue positiva y claramente apreciable, lo que sugiere que una mayor diferencia de Elo antes del partido tiende a asociarse con un mayor margen final de puntos. No se trata de una relación perfecta, ya que en el deporte siempre existe un grado de variabilidad, pero sí que muestra una tendencia clara.

8. DASHBOARDS EN POWER BI

El archivo ***DASHBOARD_FINAL_PROJECT.pbix*** incluye cuatro dashboards principales.

8.1. Dashboard 1: NBA Overview

Este *dashboard* ofrece una visión general del conjunto de datos. Incluye KPIs principales como *Total Team-Games*, *Total Seasons*, *Average Team Score*, o *Win %*. También incluye visualizaciones sobre la evolución de la anotación media por temporada, la distribución por tipo de partido y la comparación de victorias entre local y visitante. Este dashboard sirve como página inicial del informe y da una perspectiva rápida de las principales tendencias del conjunto de datos.

8.2. Dashboard 2: Team Performance

Este dashboard se centra en el rendimiento de los equipos. Incluye KPIs como número de victorias, derrotas, *Win %*, puntos anotados, puntos recibidos y margen medio de puntos. También incluye un ranking de equipos por porcentaje de victorias y un gráfico de dispersión que compara rendimiento ofensivo y defensivo. Este dashboard permite explorar qué equipos han rendido mejor en función de los filtros seleccionados, y si su rendimiento se explica más por capacidad ofensiva o defensiva.

8.3. Dashboard 3: Game Style & Box Score Analysis

Este dashboard analiza el estilo de juego y las estadísticas de *box score*, que incluye KPIs de puntos, FG %, triples intentados, 3PT %, rebotes, asistencias y pérdidas.

Uno de los elementos principales es la evolución de los tiros de campo y triples intentados por temporada, donde se observa claramente el aumento del número de triples intentados conforme

pasan los años. También se incluye una comparación de métricas de *box score* entre victorias y derrotas. Su objetivo es mostrar cómo se juega y qué estadísticas están asociadas con ganar.

8.4. Dashboard 4: Elo & Forecast Accuracy

Este dashboard analiza la capacidad predictiva del sistema Elo. Incluye KPIs como *Favorite Win %*, *Average Forecast*, *Average Score Diff.* o *Average Elo Variation*.

También incluye un gráfico de *Win %* en función de la *Favorite_Category*, un recuento de resultados esperados e inesperados, y un gráfico de dispersión que relaciona *Elo_Diff_PreGame* con *Score_Diff*.

Este dashboard muestra que el sistema Elo no predice los resultados de manera perfecta, pero sí que ofrece una orientación clara: los favoritos ganan más y las diferencias mayores de Elo tienden a asociarse con márgenes mayores en el marcador.

9. RESULTADOS PRINCIPALES

Los principales resultados obtenidos fueron los siguientes:

1. El conjunto de datos final contiene 71.984 filas y 47 columnas, con información de 31 temporadas y 36 equipos/franquicias.
2. La anotación media por equipo-partido fue de 100,52 puntos.
3. La ventaja local es clara: los equipos locales ganaron el 61,79% de sus partidos.
4. Los equipos ganadores presentan, de media, mejores métricas de *box score*: más puntos, asistencias, rebotes y robos, y menos pérdidas.
5. El volumen de triples intentados aumentó de forma muy marcada entre 1984/1985 y 2014/2015.
6. Los favoritos según Elo ganaron el 65,54% de los partidos, frente al 34,53% de los *underdogs*.
7. La categoría de favorito muestra una relación gradual con la probabilidad real de victoria.
8. *Elo_Diff_PreGame* y *Score_Diff* presentan una correlación positiva, lo que indica que una mayor ventaja Elo tiende a asociarse con mayor diferencia final de puntos.

11. CONCLUSIONES

Este proyecto permitió aplicar de manera completa un flujo de trabajo de análisis de datos: limpieza, transformación, unión de conjuntos de datos, análisis descriptivo, análisis estadístico, visualización y creación de dashboard operativo.

Desde el punto de vista analítico, los resultados muestran patrones consistentes y fáciles de interpretar: existe una ventaja local clara, los equipos ganadores presentan mejores métricas de *box score*, el estilo de juego evolucionó hacia un mayor uso del triple y el sistema Elo tiene una capacidad predictiva razonable.

Desde el punto de vista técnico, el proyecto me permitió trabajar con problemas habituales en análisis de datos reales: valores nulos, columnas redundantes, formatos inconsistentes, cambios de nombres en entidades históricas, creación de variables nuevas y combinación de fuentes heterogéneas.

Finalmente, Power BI me permitió transformar el conjunto de datos final en un informe interactivo dividido en cuatro páginas, facilitando la exploración de los datos por temporada, equipo, rival, tipo de partido, condición local/visitante y categoría de favorito. **En conjunto, el proyecto constituye una aplicación completa del ciclo de vida de un análisis de datos real.**